

Proiect ETL DavaX

Integrarea datelor, modelare dimensională
și raportare

Documentație tehnică finală

Tehnologie:	Oracle Database / Oracle SQL Developer
Arhitectură:	Source → Staging → Target
Model analitic:	Star Schema
Surse integrate:	Timesheets, Absences, Training, DU Schedule

Echipă:

Bianca – Timesheets
Lucian – Absences
Matei – Training Attendance
Andrei – DU Exam & Absence Schedule
Cristina – Star Schema & Reporting

Cuprins

1	Introducere	4
1.1	Contextul proiectului	4
1.2	Obiective	4
2	Cerințele proiectului	5
3	Arhitectura ETL	6
4	Sursele de date	7
4.1	Timesheets	7
4.1.1	Structura sursei	7
4.1.2	Probleme identificate	7
4.1.3	Reguli de curățare	7
4.2	Absences	8
4.2.1	Structura și normalizarea	8
4.3	Training Attendance	8
4.3.1	Transformări	8
4.4	DU Exam & Absence Schedule	9
4.4.1	Problema formatului matriceal	9
4.4.2	Transformarea UNPIVOT	9
5	Transformările ETL	10
6	Modelul dimensional	11
6.1	Granularitatea tabeli de fapte	11
6.2	Schema Star	12
7	Structura tabelelor Target	13
7.0.1	DIM_EMPLOYEE	13
7.0.2	DIM_DATE	13
7.0.3	DIM_PROJECT	13
7.0.4	DIM_ACTIVITY_TYPE	13
7.0.5	DIM_TRAINING	13

7.0.6	FACT_ACTIVITY	13
7.0.7	AUDIT_LOAD	14
8	Rapoarte și interogări demonstrative	15
8.1	Activitatea unui angajat într-o zi	15
8.2	Raport lunar agregat	16
8.3	Participarea lunară la training	16
8.4	Alte rapoarte disponibile	17
9	Concluzii	18

Listă de figuri

6.1 Schema Star a proiectului DavaX	12
---	----

Listă de tabele

2.1	Maparea cerințelor pe soluția implementată	5
-----	--	---

1. Introducere

1.1 Contextul proiectului

Proiectul simulează un scenariu real de integrare a datelor în care informațiile despre activitatea angajaților provin din sisteme operaționale independente. Obiectivul este construirea unei imagini unificate asupra activităților zilnice ale angajaților și pregătirea datelor pentru interogare, analiză și raportare.

Sursele integrate sunt:

- **Timesheets** – ore lucrate, angajat, dată și proiect;
- **Absences** – concedii anuale, concedii medicale și alte absențe;
- **Training Attendance** – participarea angajaților la cursuri;
- **DU Exam & Absence Schedule** – un program zilnic în format matriceal, transformat în format tabelar.

1.2 Obiective

Soluția urmărește:

- integrarea tuturor surselor într-un model analitic comun;
- păstrarea trasabilității prin metadata precum sistemul sursă și momentul încărcării;
- standardizarea și validarea datelor înainte de încărcarea în modelul final;
- interogarea activității unui angajat pentru o dată selectată;
- obținerea rapoartelor lunare agregate;
- extinderea facilă cu surse noi.

2. Cerințele proiectului

Tabela 2.1: Maparea cerințelor pe soluția implementată

Cerință	Implementare
Arhitectură pe straturi	Tabele și scripturi separate pentru Source, Staging și Target.
Model Star Schema	FACT_ACTIVITY conectată la DIM_EMPLOYEE, DIM_DATE, DIM_PROJECT, DIM_ACTIVITY_TYPE și DIM_TRAINING.
Metadata de ingestie	SOURCE_SYSTEM și LOAD_TIMESTAMP în tabela de fapte; AUDIT_LOAD pentru evidența proceselor ETL.
Activitatea angajatului într-o zi	Query parametrizat după EMPLOYEE_ID și data selectată.
Raport lunar	Agregări după an, lună, tip de activitate și training.
Validare Source-Target	Scripturi de profilare și validare pentru fiecare modul și verificări de integritate în tabela de fapte.
Extensibilitate	Modelul dimensional permite adăugarea unor noi tipuri de activitate și noi surse fără schimbarea structurii principale.

3. Arhitectura ETL

Fluxul ETL implementat urmează arhitectura clasică în trei straturi:

Source → **Staging** → **Target**

Datele brute sunt importate și păstrate în stratul **Source**. În stratul **Staging**, acestea sunt curățate, standardizate și transformate. Datele pregătite sunt apoi încărcate în stratul **Target**, format din modelul dimensional utilizat pentru interogări și raportare.

4. Sursele de date

4.1 Timesheets

4.1.1 Structura sursei

Fișierul Timesheets conține identificatorul pontajului, datele angajatului, data lucrată, proiectul și numărul de ore. Tabela Source păstrează inclusiv data și orele ca text pentru a conserva forma inițială.

4.1.2 Probleme identificate

În urma profilării au fost identificate:

- 3074 de rânduri inițiale și 80 de angajați distincți;
- spații inutile în identificatorii angajaților;
- identificatori scriși cu litere mici și mari;
- coduri de proiect neuniforme, de exemplu PRJ01 și PRJ-01;
- nume de proiect cu capitalizare diferită;
- 61 de valori lipsă pentru numele proiectului;
- 24 de înregistrări duplicate după cheia de business;
- data și numărul de ore stocate ca text.

4.1.3 Reguli de curățare

- TRIM pentru eliminarea spațiilor;
- UPPER pentru identificatorii angajaților;
- INITCAP(LOWER(...)) pentru attribute descriptive;
- REPLACE(ProjectCode, '-', '') pentru codurile proiectelor;

- `NVL(..., 'Unknown Project')` pentru proiectele fără nume;
- `TO_DATE` și `TO_NUMBER` pentru conversia tipurilor;
- `ROW_NUMBER()` peste cheia de business pentru eliminarea duplicatelor.

După deduplicare au fost încărcate 3050 de rânduri curate în Staging.

4.2 Absences

4.2.1 Structura și normalizarea

Sursa conține intervale de absență definite prin data de început și data de sfârșit. Tipurile de absență sunt normalizate astfel:

- AL sau ANNUAL LEAVE → Annual Leave;
- SL sau SICK LEAVE → Sick Leave;
- alte valori → Unknown și stare invalidă.

4.3 Training Attendance

4.3.1 Transformări

Datele despre training sunt standardizate prin:

- transformarea identificatorului angajatului în litere mari;
- capitalizarea uniformă a numelui, gradului, disciplinei, managerului, trainingului și categoriei;
- conversia datei prin `TO_DATE`;
- păstrarea duratei în ore și a statusului participării.

În Target sunt populate `DIM_TRAINING`, `DIM_EMPLOYEE`, `DIM_DATE`, `DIM_ACTIVITY_TYPE` și `FACT_ACTIVITY`. Pentru activitățile de training, `PROJECT_KEY` este NULL, iar `TRAINING_KEY` este completată.

4.4 DU Exam & Absence Schedule

4.4.1 Problema formatului matriceal

Fișierul conține câte un rând pentru fiecare angajat și câte o coloană pentru fiecare zi din lunile iunie și iulie. Celulele conțin coduri precum W, TR, EX, AL și SL.

Acest format nu este potrivit pentru un model dimensional, deoarece numărul coloanelor depinde de perioada raportată.

4.4.2 Transformarea UNPIVOT

Operația UNPIVOT transformă structura:

Employee		01-Jun		02-Jun		03-Jun
----------	--	--------	--	--------	--	--------

în:

Employee		ActivityDate		ActivityCode
----------	--	--------------	--	--------------

Ulterior, codurile sunt mapate la categorii de activitate, iar fiecare rând este încărcat în FACT_ACTIVITY.

5. Transformările ETL

Curățarea și standardizarea datelor au fost realizate în stratul Staging, fără modificarea valorilor brute păstrate în Source. Principalele transformări aplicate sunt:

- eliminarea spațiilor inutile prin `TRIM`;
- standardizarea identificatorilor prin `UPPER`;
- uniformizarea atributelor descriptive prin `INITCAP(LOWER(...))`;
- conversia datelor și valorilor numerice prin `TO_DATE` și `TO_NUMBER`;
- normalizarea codurilor de proiect și a tipurilor de activitate;
- înlocuirea controlată a valorilor lipsă;
- eliminarea duplicatelor pe baza cheilor de business;
- transformarea structurii matriceale `DU Schedule` în rânduri prin `UNPIVOT`;
- maparea cheilor de business la cheile surogat din dimensiuni;
- încărcarea activităților din toate sursele în `FACT_ACTIVITY`.

Încărcările dimensiunilor și tabelii de fapte folosesc condiții de tip `NOT EXISTS` sau operații `MERGE`, astfel încât scripturile să poată fi rulate repetat fără inserarea acelorași entități de mai multe ori.

6. Modelul dimensional

6.1 Granularitatea tabelii de fapte

Granularitatea stabilită este:

Un rând din FACT_ACTIVITY reprezintă o activitate a unui angajat într-o anumită zi.

Această granularitate permite combinarea activităților de lucru, absență, training și examen într-o structură comună.

6.2 Schema Star




Figura 6.1: Schema Star a proiectului DavaX

7. Structura tabelelor Target

7.0.1 DIM_EMPLOYEE

Conține atributele descriptive ale angajatului: identificator de business, nume, grad, disciplină, manager și Delivery Unit. EMPLOYEE_KEY este o cheie surogat generată automat, iar EMPLOYEE_ID este unic.

7.0.2 DIM_DATE

Conține atribute calendaristice pentru raportare: zi, lună, trimestru, an, săptămână, numele zilei și indicatorul de weekend. DATE_KEY are formatul numeric YYYYMMDD.

7.0.3 DIM_PROJECT

Conține codul și numele proiectului. Este utilizată în principal de activitățile provenite din Timesheets.

7.0.4 DIM_ACTIVITY_TYPE

Conține tipurile standardizate de activitate și categoria lor, de exemplu Work, Training, Exam, Annual Leave și Sick Leave.

7.0.5 DIM_TRAINING

Conține denumirea unică și categoria fiecărui training.

7.0.6 FACT_ACTIVITY

Conține cheile surogat către dimensiuni, numărul de ore, sistemul sursă și momentul încărcării. PROJECT_KEY și TRAINING_KEY sunt opționale deoarece nu toate tipurile de activitate sunt asociate cu un proiect sau training.

7.0.7 AUDIT_LOAD

Tabela de audit este separată de Star Schema și păstrează rezultatul fiecărei rulări ETL: datasetul, numărul de rânduri sursă, numărul de rânduri încărcate, statusul și mesajul de eroare.

8. Rapoarte și interogări demonstrative

8.1 Activitatea unui angajat într-o zi

Interogarea folosește variabile de substituție Oracle și returnează toate activitățile unui angajat pentru data selectată.

Listing 8.1: Activitatea unui angajat la o dată selectată

```
1 SELECT
2     e.employee_id,
3     e.employee_name,
4     d.full_date,
5     a.activity_type_name,
6     NVL(p.project_name, '-') AS project_name,
7     NVL(t.training_name, '-') AS training_name,
8     f.hours_worked,
9     f.source_system
10 FROM fact_activity f
11 JOIN dim_employee e
12     ON e.employee_key = f.employee_key
13 JOIN dim_date d
14     ON d.date_key = f.date_key
15 JOIN dim_activity_type a
16     ON a.activity_type_key = f.activity_type_key
17 LEFT JOIN dim_project p
18     ON p.project_key = f.project_key
19 LEFT JOIN dim_training t
20     ON t.training_key = f.training_key
21 WHERE e.employee_id = '&EMPLOYEE_ID'
22     AND d.full_date = TO_DATE('&SELECTED_DATE', 'YYYY-MM-DD')
23 ORDER BY a.activity_type_name;
```

8.2 Raport lunar agregat

Listing 8.2: Raport lunar pe tipuri de activitate și participare la training

```
1 SELECT
2     d.year_number,
3     d.month_number,
4     d.month_name,
5     a.activity_type_name,
6     COUNT(*) AS total_activities,
7     COUNT(DISTINCT f.employee_key) AS distinct_employees,
8     COUNT(f.training_key) AS training_participations,
9     SUM(NVL(f.hours_worked, 0)) AS total_hours
10 FROM fact_activity f
11 JOIN dim_date d
12     ON d.date_key = f.date_key
13 JOIN dim_activity_type a
14     ON a.activity_type_key = f.activity_type_key
15 GROUP BY
16     d.year_number,
17     d.month_number,
18     d.month_name,
19     a.activity_type_name
20 ORDER BY
21     d.year_number,
22     d.month_number,
23     a.activity_type_name;
```

8.3 Participarea lunară la training

Listing 8.3: Participări lunare pentru fiecare training

```
1 SELECT
2     d.year_number,
3     d.month_number,
4     d.month_name,
5     t.training_name,
6     COUNT(*) AS participants
7 FROM fact_activity f
8 JOIN dim_date d
9     ON d.date_key = f.date_key
```

```
10 JOIN dim_training t
11     ON t.training_key = f.training_key
12 GROUP BY
13     d.year_number,
14     d.month_number,
15     d.month_name,
16     t.training_name
17 ORDER BY
18     d.year_number,
19     d.month_number,
20     t.training_name;
```

8.4 Alte rapoarte disponibile

Proiectul include interogări pentru:

- numărul activităților pentru fiecare sistem sursă;
- numărul total de activități din FACT_ACTIVITY;
- totalul orelor pe sursă;
- activități grupate după tip și categorie;
- totalul orelor pentru fiecare angajat;
- primii zece angajați după numărul activităților;
- activități și ore pe Delivery Unit;
- activități și ore pe proiect;
- participări pentru fiecare training;
- raportul detaliat al tuturor activităților.

9. Concluzii

Proiectul implementează un flux ETL complet pentru integrarea datelor provenite din patru surse independente într-un model dimensional de tip Star Schema. Soluția respectă arhitectura Source-Staging-Target, standardizează informațiile provenite din sisteme diferite și oferă o bază unificată pentru interogarea activităților angajaților și generarea rapoartelor lunare.